ОТЧЕТ ПО СОЗДАНИЮ СВОЕЙ MINIDB

1. Общее описание

MiniDB это файловая мини-СУБД на Python, написанная только на стандартной библиотеке. Данные хранятся в бинарных файлах собственного формата. База это папка, а каждая таблица это один файл `.tbl`. Схема таблицы хранится в заголовке её файла, поэтому после перезапуска программы таблицы и данные восстанавливаются без дополнительной конфигурации.

2. Архитектура

Проект разделён на слои, каждый знает только о слое ниже:

Слой	Модуль	Назначение
Интерфейс	`cli.py`, `demo.py`	разбор команд, вывод результата таблицей
База данных	`database.py`	набор таблиц, проверка FOREIGN KEY
Таблица	`table.py`, `query.py`	CRUD, PRIMARY KEY, условия WHERE
Схема и типы	`schema.py`, `types.py`	столбцы, перевод строк в байты и обратно, типы
Хранилище	`storage.py`	чтение и запись записей в файле по номеру
Ошибки	`errors.py`	собственные исключения

Ссылочная целостность реализована на уровне `Database`, так как отдельная таблица ничего не знает о соседних.

3. Формат хранения

Файл таблицы состоит из заголовка фиксированного размера (1024 байта) и записей фиксированной длины:

[заголовок 1024 байта][запись 0][запись 1][запись 2]...
смещение записи n = 1024 + n * размер_записи

Заголовок содержит сигнатуру `MDB1`, счётчик `next_id` для авто-ID, число столбцов, индекс PRIMARY KEY, описание каждого столбца (имя, код типа, длина) и описание связей FOREIGN KEY (столбец, таблица, столбец в ней).

Запись состоит из флага «жива/удалена» (1 байт) и значений полей по порядку столбцов.

Фиксированная длина записей позволяет вычислять смещение по формуле и перезаписывать запись на месте. Для кодирования используется модуль `struct` с порядком байт little-endian.

4. Типы данных

Тип	Размер	Кодирование
INT	8 байт	знаковое целое, `<q`
FLOAT	8 байт	число двойной точности, `<d`
STRING(N)	N байт (1-255)	UTF-8, добивается нулевыми байтами

Каждый тип реализует единый интерфейс: `validate` (проверка значения), `pack` (значение в байты), `unpack` (байты в значение), `parse` (перевод текста из CLI в значение нужного типа). Проверка типов строгая: строка в INT-поле, `bool` вместо числа, нечисловые значения FLOAT (`nan`, `inf`), строки длиннее поля и строки с нулевым символом отвергаются с понятным сообщением.

5. Схема данных

Таблица	Поля
`datasets`	`id` (PK), `name`, `task`, `size`
`models`	`id` (PK), `name`, `version`
`experiments`	`id` (PK), `dataset_id` (FK → `datasets.id`), `model_id` (FK → `models.id`), `accuracy`, `status`

6. Реализованные операции

- **CREATE TABLE.** Задаются имя таблицы, поля, их типы, PRIMARY KEY и при необходимости FOREIGN KEY. Проверяются имена, повторы столбцов, существование PK (он должен быть типа INT) и таблицы, на которую ссылается FK. Повторное создание существующей таблицы даёт ошибку.
- **INSERT.** Поддерживаются авто-ID и ручное указание id. Перед записью проверяются все поля и типы, и файл не изменяется, если есть ошибка.
- **SELECT.** Можно выбрать нужные столбцы или все. Фильтры `=`, `!=`, `>`, `<`, `>=`, `<=`. Условие проверяется до обхода файла: существование столбца, допустимость оператора, тип значения. Удалённые записи пропускаются.
- **UPDATE.** Изменяются записи, подходящие под условие, на месте. PRIMARY KEY менять нельзя. Сначала упаковываются все новые записи, и только потом они пишутся в файл, поэтому при ошибке типа ничего не меняется. Возвращается число изменённых записей.

- **DELETE.** Мягкое удаление: меняется только байт-флаг записи, смещения остальных записей не сдвигаются. Возвращается число удалённых записей.
- **Защита от случайных действий.** UPDATE и DELETE без условия запрещены, для всей таблицы нужно явно указать флаг (`all` в CLI).

7. Ограничения целостности

- **PRIMARY KEY.** Должен быть типа INT и положительным. Дубликаты запрещены.
- **Авто-ID.** Счётчик `next_id` хранится в заголовке файла и не уменьшается при удалении, поэтому идентификатор удалённой записи не выдаётся повторно, в том числе после перезапуска.
- **FOREIGN KEY при INSERT и UPDATE.** Нельзя добавить или изменить `experiment` с несуществующим `dataset_id` или `model_id`.
- **Запрет удаления родителя.** Нельзя удалить запись из `datasets` или `models`, если на неё ссылается хотя бы один `experiment`. Операция отменяется целиком.
- Связи хранятся в заголовке файла, поэтому проверки работают и после перезапуска.

8. Обработка ошибок

Все ошибки наследуются от общего `MiniDBError`:

Исключение	Когда возникает
`ValidationError`	неверный тип или значение, неверное условие, неизвестный столбец
`SchemaError`	неверное описание таблицы, таблица не найдена или уже существует
`IntegrityError`	дубликат PRIMARY KEY, нарушение FOREIGN KEY
`StorageError`	повреждённый, обрезанный или чужой файл

CLI перехватывает `MiniDBError` и выводит одно понятное сообщение вместо traceback. Повреждённые файлы распознаются при открытии базы (проверяются сигнатура, заголовок и кратность размера файла размеру записи).

9. Консольный интерфейс

Команды: `tables`, `describe`, `create`, `insert`, `select`, `update`, `delete`, `help`, `exit`. Значения из текста приводятся к типу столбца по схеме таблицы, значения с пробелами задаются в кавычках. Результат выводится в виде таблицы. Через CLI можно создавать таблицы со связями.

Пример:

```
select experiments columns id,accuracy where accuracy > 0.9
insert experiments dataset_id=1 model_id=1 accuracy=0.85 status=running
update experiments set status=completed where id = 21
delete experiments where id = 21
```

10. Тестовые данные

Скрипт `seed.py` создаёт базу из 5 datasets, 5 models и 20 experiments. Данные генерируются с фиксированным seed, поэтому одинаковы при каждом запуске. Первые три эксперимента совпадают с примером из задания. Готовая база лежит в папке `data/`.

11. Тестирование и демонстрация

Автотесты (30 проверок) покрывают все слои:

- типы и их граничные случаи;
- хранилище: запись, перезапуск, UPDATE и DELETE на месте;
- таблицы и CRUD: все операторы сравнения, выбор столбцов, персистентность;
- обработка ошибок и повреждённые файлы;
- ссылочная целостность и генератор данных;
- реальная сессия CLI через стандартный ввод.

11. Бенчмарк

Результаты benchmark

Окружение: Python 3.12.3, Linux x86_64. Таблица `experiments` с N записями (datasets и models по 5). Время операций над одной записью усреднено по 5 случайным id, SELECT с фильтром и SELECT * по 3 запускам.

Записей	Файл, КБ	INSERT всех, с	INSERT одной, мс	SELECT *, мс	SELECT WHERE id=?, мс	SELECT WHERE accuracy>0.9, мс	UPDATE по id, мс	DELETE по id, мс	INSERT с ручным id, мс
1,000	49	0.05	0.051	5.3	4.5	6.3	4.8	8.7	4.4
10,000	480	0.52	0.052	56.5	60.5	48.2	61.3	64.5	88.9
100,000	4786	6.50	0.065	796.9	516.0	592.9	525.0	533.2	522.9

Поиск, UPDATE, DELETE и проверка дубликата при ручном id идут полным проходом по файлу, поэтому их время растёт пропорционально числу записей. INSERT с авто-ID не зависит от размера таблицы: запись дописывается в конец файла.

11. Примеры выполнения операций в cli

команда help

```
minidb> help
Команды:
  tables                              список таблиц
  describe <table>                    столбцы, PK, связи
  create <table> <col:TYPE> ... pk=<col> [fk=<col>:<table>.<col> ...]
        TYPE: INT, FLOAT, STRING(16)
  insert <table> col=val ...
  select <table> [columns a,b] [where col op value]
  update <table> set col=val ... where col op value      (или "all" вместо where)
  delete <table> where col op value                      (или "delete <table> all")
  help, exit
Операторы: = != > < >= <=      Значения с пробелами: name="Fashion MNIST"
Примеры:
  insert experiments dataset_id=1 model_id=2 accuracy=0.9 status=running
  select experiments columns id,accuracy where status = completed
  update experiments set status=completed where id = 3
  delete experiments where id = 3
```

команда describe - описание одной таблицы

```
minidb> describe experiments
  id            INT         PRIMARY KEY
  dataset_id    INT         -> datasets.id
  model_id      INT         -> models.id
  accuracy      FLOAT
  status        STRING(16)
```

create, insert, update, delete and select:

```
minidb> create students id:INT name:STRING(32) university:STRING(32) pk=id
Таблица students создана
minidb> insert students name:Maria university:HSE
Ошибка (ValidationError): Ожидалось столбец=значение, получено 'name:Maria'
minidb>  insert students name=Maria university=HSE
Вставлено, id = 1
minidb> select students
id | name  | university
---+-------+-----------
1  | Maria | HSE
(1 строк)
minidb> update students set university="HSE NN" where id=1
Обновлено записей: 1
minidb> select students
id | name  | university
---+-------+-----------
1  | Maria | HSE NN
(1 строк)
minidb> insert students name="Anastasia" university="pedkolledzh"
Вставлено, id = 2
minidb> select students
id | name      | university
---+-----------+------------
1  | Maria     | HSE NN
2  | Anastasia | pedkolledzh
(2 строк)
minidb> delete students where id=1
Удалено записей: 1
minidb> select students
id | name      | university
---+-----------+------------
2  | Anastasia | pedkolledzh
(1 строк)
```

создание таблиц с fk

```
minidb> create authors id:INT name:STRING(32) country:STRING(24) pk=id
Таблица authors создана
minidb> create books id:INT author_id:INT title:STRING(64) year:INT pk=id fk=author_id:authors.id
Таблица books создана
minidb> insert authors name="Лев Толстой" country=Russia
Вставлено, id = 1
minidb> insert authors name="Джейн Остин" country=England
Вставлено, id = 2
minidb> insert authors name="Марк Твен" country=USA
Вставлено, id = 3
minidb> insert books author_id=1 title="Война и мир" year=1869
Вставлено, id = 1
minidb> insert books author_id=2 title="Гордость и предубеждение" year=1813
Вставлено, id = 2
minidb> insert books author_id=3 title="Приключения Тома Сойера" year=1876
Вставлено, id = 3
minidb> select books
id | author_id | title                    | year
---+-----------+--------------------------+-----
1  | 1         | Война и мир              | 1869
2  | 2         | Гордость и предубеждение | 1813
3  | 3         | Приключения Тома Сойера  | 1876
(3 строк)
minidb> describe books
  id            INT         PRIMARY KEY
  author_id     INT         -> authors.id
  title         STRING(64)
  year          INT
minidb> select authors
id | name         | country
---+--------------+--------
1  | Лев Толстой | Russia
2  | Джейн Остин | England
3  | Марк Твен   | USA
(3 строк)
minidb> describe authors
  id            INT         PRIMARY KEY
  name          STRING(32)
  country       STRING(24)
minidb>
```